Progetto Bioinformatica (Tema 2)

Francesco Fusi 899741
A.A.2024/2025

Obiettivo del progetto

L'obiettivo del progetto è lo sviluppo di uno script in Python in grado di identificare, partendo da due file, uno in formato GTF e l'altro in formato BAM, il `transcript_id` che presenta il maggior numero di match con i reads allineati nel file BAM.

File di Input

I due file forniti contenenti le informazioni per lo sviluppo del programma sono:

- **File GTF**: fornisce i trascritti di geni umani su un determinato cromosoma (es. cromosoma 8 o 21).
  Ogni riga descrive un esone e include le seguenti informazioni rilevanti:
  - Coordinate: Start ed End
  - Attributi: `gene_id` e `transcript_id`

  Nel nostro caso il file contiene esoni di un solo cromosoma.
- **File BAM**: fornisce gli allineamenti di reads trascrittomici ottenuti in laboratorio tramite sequenziamento. I reads sono allineati rispetto ai trascritti presenti nel file GTF.

Algoritmo per l'estrazione del gene più frequente

1. Lettura del GTF riga per riga e creazione di un dataframe con le informazioni necessarie per un'analisi efficiente durante la fase di confronto.
2. Analisi di ciascun read presente nel file BAM tramite la CIGAR string che descrive come ogni read si allinea al genoma.
3. I reads vengono suddivisi in due categorie:
   - **Unspliced**: allineati in un'unica regione continua
   - **Spliced**: contenenti salti (indicati come `N` nella CIGAR), e quindi indicativi di splicing tra esoni
4. Estrazione, per ogni read spliced, delle porzioni allineate e confronto con le coordinate Start ed End degli esoni nel GTF.

5. Determinazione, per ciascun esone, del numero di reads che si sovrappongono.

6. Associazione di un contatore a ciascun `transcript_id` che permette di valutare la frequenza con la quale un esone si associa ad un read del file BAM.

7. Identificazione del `transcript_id` con il numero più alto di match.

Come output viene stampato a video l'esone con la frequenza di sovrapposizione maggiore.

Algoritmo per l'estrazione dei Reads Spliced in formato FASTQ

I reads classificati come spliced e che si allineano al trascritto selezionato vengono estratti dal BAM e salvati in un file in formato FASTQ.

Il formato FASTQ riporta le informazioni di un read in quattro righe, composte nel seguente modo: identificativo del read, sequenza nucleotidica letta, un separatore (+) e la stringa di qualità dalla quale è possibile estrarre il grado di affidabilità del sequenziamento.

Librerie utilizzate

- **Pysam**: utilizzata per leggere e manipolare il file BAM, estrarre informazioni (es. CIGAR, posizioni di allineamento) e per iterare efficientemente sui reads.
- **Pandas**: utilizzata per la gestione dei dati del GTF.
- **Collections.defaultdict**: utilizzata per contare comodamente le occorrenze di reads che coprono ciascun esone senza dover inizializzare manualmente le chiavi.